



UNIVERSIDADE FEDERAL DO PARANÁ
SETOR DE CIÊNCIAS DA TERRA
DEPARTAMENTO DE GEOMÁTICA



AJUSTAMENTO 2 – GA110 A ENGENHARIA CARTOGRÁFICA E DE AGRIMENSURA

Prof. Dr. Mario Ernesto Jijón Palma

Departamento de Geomática

Setor de Ciências da Terra

Universidade Federal do Paraná - UFPR



Ajustamento – Método dos Mínimos Quadrados

Método paramétrico $L_a = F(X_a)$

Os valores observados ajustados podem ser expressos explicitamente como uma função dos parâmetros ajustados.

Método dos correlatos $F(L_a) = 0$

Os valores observados ajustados devem satisfazer determinadas condições (erro de fechamento = zero).

Método combinado $F(L_a, X_a) = 0$

Os valores observados ajustados e os parâmetros ajustados são ligados por função não explícita (não se consegue separa-los).

Ajustamento: Método Paramétrico



$$L_a = F(X_a)$$

- Método das observações indiretas, as grandezas buscadas (parâmetros) não são medidas diretamente, mas relacionadas matematicamente com outras que são medidas.
- Cada observação fornece uma equação. Se temos **n** observações, teremos **n** equações.
- Os parâmetros a estimar são representados por **u** variáveis.



Ajustamento: Método Paramétrico



Linear

Resolução direta (uma única etapa para encontrar a solução)

Não é necessário uma aproximação inicial

Exemplo: Nivelamento, Poligonais

Não Linear

Para resolver o sistema tem que se linearizar pela fórmula de Taylor.

Resolução Iterativa (requer um processo de repetição para encontrar a solução)

Necessita de uma aproximação inicial para começar o processo iterativo.

Exemplo: Ajustamento de redes geodésicas, fotogrametria, GPS.

Ajustamento: Método Paramétrico



$$L_a = F(X_a)$$

Sejam:

L_b = Vetor dos valores observados;

V = Vetor dos resíduos;

L_a = Vetor dos valores observados ajustados.

X_0 = Vetor com valores aproximados dos parâmetros;

X = Vetor correção;

X_a = Vetor dos parâmetros ajustados (um dos objetivos).

$$L_a = L_b + V$$

$$X_a = X_0 + X$$

Ajustamento: Método Paramétrico



Linear

$$L_a = F(X_a)$$

$$X = (A^T * P * A)^{-1} * (A^T * P * L_b)$$

$$N = (A^T * P * A)$$

$$U = (A^T * P * L_b)$$

Ajustamento: Método Paramétrico



PASSOS PARA RESOLVER METODO PARAMÉTRICO LINEAR

a) Modelo Matemático $L_a = F(X_a)$ $L_a = L_b + V$

b) Matriz das observações L_b

c) Calcular a matriz dos pesos P

d) Calcular o vetor das observações aproximadas: modelo linear

$$X_0 = 0 \rightarrow L_0 = F(X_0)$$

e) Calcular a matriz $L = L_0 + L_b$

f) Calcular a matriz A (derivadas parciais) $A = \frac{\partial F}{\partial X_a} |_{X_a = X_0}$

g) Calcular as equações normais $N = A^T P A$ $U = A^T P L$

$$X = N^{-1} U$$

Ajustamento: Método Paramétrico



PASSOS PARA RESOLVER METODO PARAMÉTRICO LINEAR

h) Obter a Matriz dos resíduos

$$V = A * X + L$$

i) Variância a posteriori ($\hat{\sigma}_0^2$)

$$\hat{\sigma}_0^2 = \frac{V^T P V}{n - u}$$

j) Calcular MVC dos parâmetros ajustados

$$\Sigma_X = \hat{\sigma}_0^2 N^{-1}$$

Ajustamento: Método Paramétrico



Não Linear

$$\begin{aligned} L_a &= F(X_a) & L_a &= L_b + V \\ X_a &= X_0 + X & X_a &= X_0 + X \\ L_b + V &= F(X_0 + X) \end{aligned}$$

Substituindo o primeiro membro e linearizando o segundo por Taylor:

$$L_b + V = F(X_0 + X) = F(X_0) + \left. \frac{\partial F}{\partial X_a} \right|_{X_a=X_0} * X$$

Ajustamento: Método Paramétrico



Não Linear

$$L_b + V = F(X_0 + X) = F(X_0) + \left. \frac{\partial F}{\partial X_a} \right|_{X_a=X_0} * X$$

Designando a função dos parâmetros aproximados: $L_0 = F(X_0)$

e a matriz das derivadas parciais $A = \left. \frac{\partial F}{\partial X_a} \right|_{X_a=X_0}$

tem-se: $L_b + V = L_0 + AX$ ou $V = AX + L_0 - L_b$

Fazendo-se: $L = L_0 - L_b$

Obtem-se o modelo linearizado do método paramétrico

$${}_nV_1 = {}_nA_u {}_uX_1 + {}_nL_1$$

Ajustamento: Método Paramétrico



Não Linear

$${}_nV_1 = {}_nA_u {}_uX_1 + {}_nL_1$$

$$\begin{bmatrix} v_1 \\ v_2 \\ \dots \\ v_n \end{bmatrix} = \begin{bmatrix} \frac{\partial f_1}{\partial x_{a1}} & \frac{\partial f_1}{\partial x_{a2}} & \dots & \frac{\partial f_1}{\partial x_{au}} \\ \frac{\partial f_2}{\partial x_{a1}} & \frac{\partial f_2}{\partial x_{a2}} & \dots & \frac{\partial f_2}{\partial x_{au}} \\ \dots & \dots & \dots & \dots \\ \frac{\partial f_n}{\partial x_{a1}} & \frac{\partial f_n}{\partial x_{a2}} & \dots & \frac{\partial f_n}{\partial x_{au}} \end{bmatrix}_{x_0} \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix} + \begin{bmatrix} l_1 \\ l_2 \\ \dots \\ l_n \end{bmatrix}$$

O índice na parte inferior direita da matriz dos coeficientes das incógnitas lembra que as derivadas parciais são calculadas numericamente com os valores aproximados das incógnitas.

Ajustamento: Método Paramétrico



Considerações sobre a Matriz dos Pesos

Quando as observações não oferecem o mesmo “grau de confiança”, podemos “homogeneizá-las” multiplicando-as por “pesos”

$$Q = \frac{1}{\sigma_0^2} \sum L_b$$

Se a matriz Q for não singular (inversível) admitirá uma inversa

$$Q^{-1} = \sigma_0^2 \sum L_b^{-1} = P$$

que recebe o nome de matriz dos pesos.

$$p_i = \frac{\sigma_0^2}{\sigma_i^2}$$

Ajustamento: Método Paramétrico



Equações normais

Minimizando a forma quadrática fundamental, obtemos sucessivamente:

$$\varphi = V^T P V = \min \quad \text{onde: } V = A * X + L$$

$$\varphi = (AX + L)^T P (AX + L) = \min$$

$$\varphi = (X^T A^T + L^T) P (AX + L) = X^T A^T P A X + X^T A^T P L + L^T P A X + L^T P L = \min$$

$$\text{onde: } X^T A^T P L = L^T P A X$$

$$\varphi = X^T A^T P A X + 2X^T A^T P L + L^T P L = \min$$

Ajustamento: Método Paramétrico



Equações normais

$$\varphi = X^T A^T P A X + 2X^T A^T P L + L^T P L = \min$$

Igualando a zero a derivada primeira em relação a X:

$$\frac{\partial \varphi}{\partial X} = 2A^T P A X + 2A^T P L = 0$$

$$2A^T P A X + 2A^T P L = 0$$

$$X = -(A^T P A)^{-1} \cdot (A^T P L)$$

Fazendo: $N = A^T P A$ e $U = A^T P L \rightarrow X = -N^{-1}U$

cujas componentes convertem os parâmetros aproximados em ajustados:

$$X_a = X_0 + X$$

Ajustamento: Método Paramétrico



Matriz variância – covariância (MVC)

Antes do ajustamento necessitamos estimar a precisão das medidas efetuadas para compor a MVC dos valores observados ($\sum L_b$), onde

$$P = \sigma_0^2 * \sum L_b^{-1}$$

Após o ajustamento podemos estimar a variância da unidade de peso (variância a posteriori) e MVC das variáveis aleatórias envolvidas no processo

$$X, X_a, V, L_a$$

Ajustamento: Método Paramétrico



MVC das correções Σ_X

Sabendo que:

$$X = -N^{-1}U = -N^{-1}A^T P L = -N^{-1}A^T P (L_0 - L_b) \rightarrow X = -N^{-1}A^T P L_0 + N^{-1}A^T P L_b$$

Aplicando a lei de propagação das covariâncias $\Sigma_X = G \Sigma L_b G^T$

com $G = N^{-1}A^T P$

(P e N^{-1} são matrizes simétricas) $G^T = P^T A N^{-1} = P A N^{-1}$

Substituindo na equação anterior $\Sigma_X = (N^{-1}A^T P) \Sigma L_b (P A N^{-1})$

$$\Sigma_X = (N^{-1}A^T P) \sigma_0^2 P^{-1} (P A N^{-1}) = \sigma_0^2 N^{-1} A^T P A N^{-1} = \sigma_0^2 N^{-1} N N^{-1}$$

$$\Sigma_X = \sigma_0^2 N^{-1}$$

Ajustamento: Método Paramétrico



MVC dos parâmetros ajustados Σ_{Xa}

Temos que: $X_a = X_0 + X$ Como o vetor X_0 é constante, então $\Sigma_{Xa} = \Sigma_X = \sigma_0^2 N^{-1}$

MVC dos valores observados ajustados Σ_{La}

$$L_a = L_b + V = L_b + AX + L = L_b + AX + L_0 - L_b \quad \text{Temos que: } L_a = AX + L_0$$

Aplicando a lei de propagação de covariância (LPC):

$$\Sigma_{La} = A \Sigma_X A^T = \sigma_0^2 (A N^{-1} A^T)$$

MVC dos resíduos Σ_V

Temos que: $V = L_a - L_b$ Aplicando LPC: $\Sigma_V = \Sigma_{La} - \Sigma_{Lb} = \sigma_0^2 (A N^{-1} A^T) - \sigma_0^2 P^{-1}$

$$\Sigma_V = \sigma_0^2 (A N^{-1} A^T - p^{-1})$$

Ajustamento: Método Paramétrico



Variância a posteriori $\hat{\sigma}_0^2$

$$\hat{\sigma}_0^2 = \frac{V^T P V}{S}$$

Sabendo que:

$$S = n - u$$

n = equações de observação

u = parâmetros

S = graus de liberdade

Resultando em:

$$\hat{\sigma}_0^2 = \frac{V^T P V}{n - u}$$

$$V^T P V = X^T U + L^T P L$$

Ajustamento: Método Paramétrico



Análise da Variância a posteriori $\hat{\sigma}_0^2$

$$\hat{\sigma}_0^2 = \frac{V^T P V}{S}$$

Comparação entre σ_0^2 e $\hat{\sigma}_0^2$

Se $\hat{\sigma}_0^2 > \sigma_0^2 \rightarrow$ **A qualidade das observações é pior do que a suposta. Observações foram superestimadas!**

Se $\hat{\sigma}_0^2 < \sigma_0^2 \rightarrow$ **A qualidade das observações é melhor do que a suposta. Observações foram subestimadas!**

Ajustamento: Método Paramétrico



Análise da Variância a posteriori $\hat{\sigma}_0^2$

$$\hat{\sigma}_0^2 = \frac{V^T P V}{S}$$

No início de um ajustamento arbitramos, por exemplo, $\sigma_0^2 = 1$ após o ajustamento obtemos, digamos, $\hat{\sigma}_0^2 = 1,9$

Comparação entre $\sigma_0^2 = 1$ e $\hat{\sigma}_0^2 = 1,9$

A qualidade das observações foi superestimada.

Ajustamento: Método Paramétrico



Se houver discrepância, aplica-se um teste de hipótese baseado na distribuição de χ^2 para constatar se a discrepância é significativa a um certo nível de confiança.

Qualidade do ajustamento: Teste de hipótese

Hipótese nula $H_0: \sigma_0^2 = \hat{\sigma}_0^2$

Hipótese alternativa $H_a: \sigma_0^2 \neq \hat{\sigma}_0^2$

$$\text{Cálculo} \rightarrow \chi^2 = \frac{\hat{\sigma}_0^2}{\sigma_0^2} (n - u) = \frac{V^T P V}{\sigma_0^2}$$

Da tabela, exemplificando com $\alpha = 5\% \rightarrow \chi_{v;2,5\%}^2 < \chi^2 < \chi_{v;97,5\%}^2$

Nestas condições, a hipótese básica é aceita , ao nível de confiança 5%, e a qualidade do ajustamento é aceita

Ajustamento: Método Paramétrico



PASSOS PARA RESOLVER METODO PARAMÉTRICO NÃO LINEAR

1. Modelo Matemático $L_a = F(X_a)$

2. Modelo linearizado por Taylor $A * X + L = V$

a) Calcular o vetor das observações aproximadas $L_0 = F(X_0)$

$$L = L_0 + L_b$$

b) Calcular a matriz A (derivadas parciais) $A = \frac{\partial F}{\partial X_a} |_{X_a - X_0}$

c) Calcular a matriz dos pesos

d) Calcular as equações normais $N = A^T P A$ $U = A^T P L$

$$X = -N^{-1}U$$

Ajustamento: Método Paramétrico



PASSOS PARA RESOLVER METODO PARAMÉTRICO NÃO LINEAR

- e) Encontrar os parâmetros ajustados $X_a = X_0 + X$
- f) Obter a Matriz dos resíduos $V = A * X + L$
- g) Variância a posteriori ($\hat{\sigma}_0^2$) $\hat{\sigma}_0^2 = \frac{V^T P V}{n - u}$
- h) Calcular MVC dos parâmetros ajustados $\Sigma_{Xa} = \hat{\sigma}_0^2 N^{-1}$
- i) Calcular os valores observados ajustados $L_a = L_b + V$
- j) Analisar a qualidade do ajustamento: Teste de hipótese